

ПРОЕКТ
МЭРА
МОСКВЫ

БИЗНЕС
МОСКВЫ



РАЗВИТИЕ
ЧЕЛОВЕЧЕСКОГО
КАПИТАЛА



ЛИДЕРЫ
ЦИФРОВОЙ
ТРАНСФОРМАЦИИ

ALOLA ТРЕНАЖЁР ПЕРЕГОВОРОВ

Задача № 9 · API-first тренажёр для людей и переговорных агентов

КОМАНДА И РЕШЕНИЕ



**Шмелева Ольга
Васильевна**

преподаватель ВАВТ
деловой английский



**Головатюк Виталий
Владимирович**

предприниматель
кандидат юридических наук
ветеран МВД

ALOLA — AI-FIRST ТРЕНАЖЁР ПЕРЕГОВОРОВ

Человек или внешний агент ведёт переговоры через единый Player API. Детерминированный движок контролирует экономику, ограничения и подтверждение сделки. LLM отвечает за естественные формулировки и итоговый разбор.

ЧТО ОТЛИЧАЕТ РЕШЕНИЕ

Контроль


Parser → validator → engine.
Модель не может изменить
utility, hard constraints или факт
подтверждения.

Обучение

После завершённой сессии:
экономика, процесс и
коммуникация — с
доказательствами из диалога.


Проверяем переговорный навык, а не умение угадывать интерфейс.

КОМАНДА: РОЛИ И ЗОНЫ ОТВЕТСТВЕННОСТИ




Продукт

- Методика и кейсы
- ФИО - из заявки




Backend

- Движок и API
- ФИО - из заявки




Frontend

- Demo UX
- ФИО - из заявки



QA / Safety

- Регрессии и релиз
- ФИО - из заявки



Stand / Pitch

- Стенд и защита
- ФИО - из заявки

ПОЧЕМУ ЭТА ЗАДАЧА



Проблема

01

Заученные реплики не учат принимать решения под ограничениями. Нужен безопасный цикл: ход → проверка → последствие → разбор.

Почему задача № 9

02

Задача соединяет обучение людей и сравнимую проверку переговорных агентов через один Player API.

Главный инженерный риск

03

Свободный текст нельзя превращать в обязательство без подтверждения полного предложения. Парсер предлагает действие. Движок проверяет и фиксирует его.

КОРОТКО О РЕШЕНИИ



Техническая суть решения

Версионизируемые сценарии и роли
Natural language → typed action
Детерминированная валидация сделки
Raw transcript + event log
Replay, rewind и branching
Один API для людей и агентов

Ценность и внедрение

Корпоративное обучение продаж и закупок
On-premise режим для закрытых данных
Сравнение команд и внешних агентов
Быстрое добавление отраслевых кейсов
Интеграция через API и CLI
Шаблонный режим без внешних моделей

ЧЕЛОВЕК / ВНЕШНИЙ АГЕНТ

↓ natural language

PLAYER API

↓

PARSER → VALIDATOR → ENGINE

↓

EVENT LOG → REVIEW

1 · ScenarioVersion

Неизменяемая authored truth

2 · Observation

Проекция без hidden state

3 · Offer revision

Полный typed пакет условий


4 · Utility + constraints

Reservation utility - порог

5 · Review


Факты, экономика, повтор

ДЕМО: ХОД → РАЗБОР



Живой диалог

Интересы оппонента, структурированное предложение и явный выход из переговоров.



Честный разбор

Сделка ниже BATNA получает предупреждение. Награда и причинные обещания не показываются.

ПЛАН РАЗВИТИЯ



СЕЙЧАС

Parser safety
Pinned demo path

ФИНАЛ

Public filtered repo
Frozen template stand

1 МЕСЯЦ

Авторинг кейсов
Pilot analytics

1

2

3

4

5

3 МЕСЯЦА

LMS / SSO
Team dashboards

ПОСЛЕ

Agent benchmark
Private deployment

ФРЕЙМВОРКИ ПЕРЕГОВОРОВ



01

Гарвардский метод

Интересы вместо позиций. Варианты до решения. Объективные критерии. Отношения отделены от предмета сделки.

02

BATNA + reservation utility

BATNA — лучший вариант без сделки. Reservation utility — минимально приемлемый результат. Эти значения не смешиваются.

03

ZOPA + Pareto

ZOPA — множество приемлемых многомерных пакетов, а не только диапазон цены. Pareto-поиск отделяет создание ценности от её распределения.

04

Тактики Восса — опционально

Tentative labels, короткие mirrors, summaries и калиброванные вопросы «что/как» улучшают процесс. Они не меняют логику сделки.

Движок выбирает ЧТО допустимо. LLM формулирует КАК это сказать. Итоговый разбор: экономика • процесс • коммуникация.

ВЫБОР LLM: МОДЕЛЬ ПОД ЗАДАЧУ



Три контура снижают задержку и стоимость без передачи модели контроля над сделкой.

01

Диалог / NPC

deepseek-v4.1-flash

Быстрая естественная реплика.
Thinking выключен. Grounding и fallback обязательны.

02

Control tasks

deepseek-v4-flash-0731

Структурные задачи и контрольные операции. Thinking выключен. Решение проверяет движок.

03

Итоговый review

qwen3.8-max

Разбор завершённой сессии. Только sealed transcript и evidence-linked выводы.

ПОЧЕМУ ТАК

- отдельная модель для latency-sensitive диалога
- более сильная модель для редкого итогового разбора
- единый provider abstraction для OpenAI и QwenCloud
- deterministic fallback при таймауте или нарушении grounding

11 моделей · 220 сессий

Role swap · RU/EN · fresh sessions
Метрики относятся к переговорной задаче, а не к общему интеллекту.

ШКАЛЫ ОТНОШЕНИЙ



Параметры симуляции 0–100. Это не психологические измерения человека.

RAPPORT


теплота и контакт



45

CREDIBILITY


доверие к словам и обязательствам



60

TENSION

напряжение в обмене



10

PATIENCE

готовность продолжать диалог



80

Примеры событий

оскорбление: rapport –6, tension +8, patience –4 • извинение: rapport +2, tension –5 • признанная ложь: credibility –6

Шкалы меняют тон реплики. Они не меняют utility, reservation utility, hard constraints или подтверждение сделки.

ЗАЧЕМ В ПЕРЕГОВОРАХ ГУФФИ



ГУФФИ

собака NPC

**ГУФФИ НУЖЕН, ЧТОБЫ ПРОВЕРИТЬ
ЕСТЕСТВЕННОСТЬ И ГРАНИЦЫ
СОЦИАЛЬНОГО КОНТЕКСТА.**

01 Авторский личный факт

В сценарии у NPC есть собака по имени Гуффи. Это безопасная тема для естественного small talk.

02 Проверка контекста

Тема показывает внимание к деталям, память диалога и умение вернуться к коммерческому вопросу.

03 Ограниченный эффект

Уместный интерес: rapport +3. Повторение получает penalty. Credibility и экономические условия не растут.

04 Не механика скидки

В live-примере rapport вырос 55 → 58. Другие шкалы не изменились. Принятие сделки нельзя объяснять вопросом о собаке.

ДВА LLM-АГЕНТА: MCP-READY



Сейчас: Player API + CLI self-play. Следующий интерфейс: MCP-адаптер поверх тех же безопасных операций.

LLM A

Роль 1
наблюдение только своей
стороны



MCP-адаптер

MCP tools → authenticated Player
API
без обхода parser / validator /
engine



ALOLA ENGINE

Сценарий, utility, constraints,
event log, sealed review



LLM B

Роль 2
наблюдение только своей
стороны

УСЛОВИЯ СРАВНЕНИЯ

- fresh sessions и фиксированный сценарий
- смена ролей для каждого pair
- русский и английский языки
- hints выключены
- итоговый review видит sealed transcript

ЧТО ИЗМЕРЯЕМ

- agreement rate и utility
- соблюдение constraints и policy
- качество вопросов и пакетных предложений
- согласованность решений
- latency, fallback и failures

Корректный вывод: сравниваем переговорные когнитивные навыки в заданной среде. Это не рейтинг общего интеллекта LLM.